W6D1 Notes

章轩畅 2022.10.17

Outline

Question: the performance of Cache?

- 评价指标--AMAT(average memory access time)
  - $AMAT_{Mem} = T_{addressing} + T_{access} + T_{transfer}$, 其中$T_{access}$较大
  - $AMAT_{Cache} = T_{Hit} + \eta_{Miss} \cdot T_{MissPenalty}$
- Reason
- How to decrease AMAT ?
  - Miss-rate
  - Miss-penalty
  - Hit-time

Review

- Cache 产生原因：CPU与Memory发展差距大
- Cache 分类
  - Direct Mapped Cache: N=1
  - N-way Associative Cache--disadvantage: delay
  - Full Associative Cache: N=max
- Cache performance

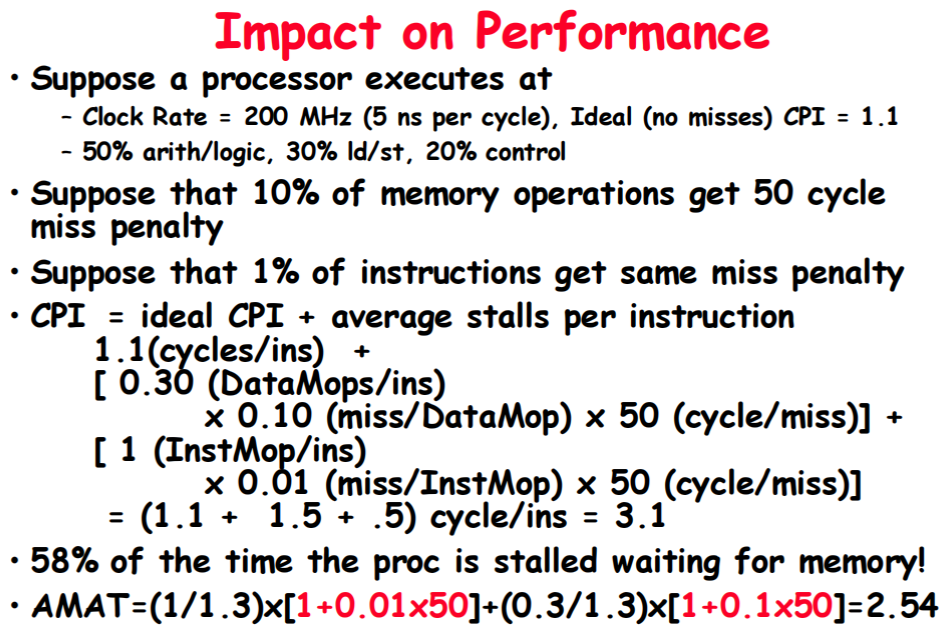

----an example of calculation

Explanation:

- ideal CPI=1 cycle/ins
- Suppose 100 instr/program, 130次Mem访问=100次取指令+30次ld/st指令

    - 由数据发现, miss-rate: ins<<mem, 于是有了指令和内存放在一起还是分开放的争论

      Von Neumam(放在一起) V.S. Havard(分开放)

- What happens on a write?
    - Write back: 数据改变后，在Cache中被替换时写回内存
    - Write through: 数据改变后立即写回内存

Reducing Misses

Miss 种类及大致解决思路

- compulsory--开始运行时的强制写入问题

  解决思路：提前预热，读入预测的访问对象数据

- capacity--容量问题

  解决思路：扩容

- Conflict--取模后冲突问题

图像分析（理解几种miss的原因）

-

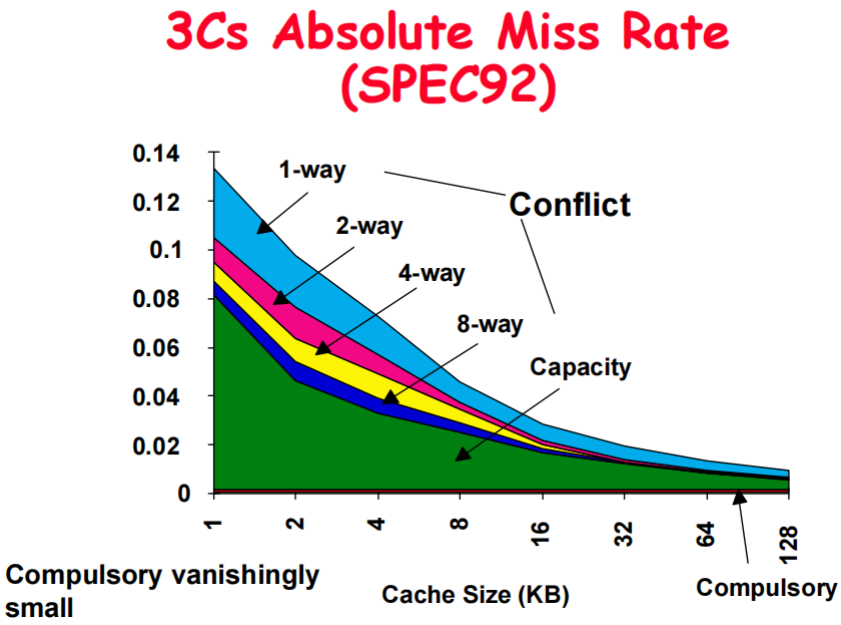

    - way增加，关联度增加，miss-rate减小--解决了Conflict问题
    - Cache size很大时，miss-rate随way增加而减小不明显--Cache size很大时，Conflict 问题较小
    - 工业上，一般而言，一级Cache(靠近core)采用直接映射，中间的Cache采用多路映射，提高相关性
-

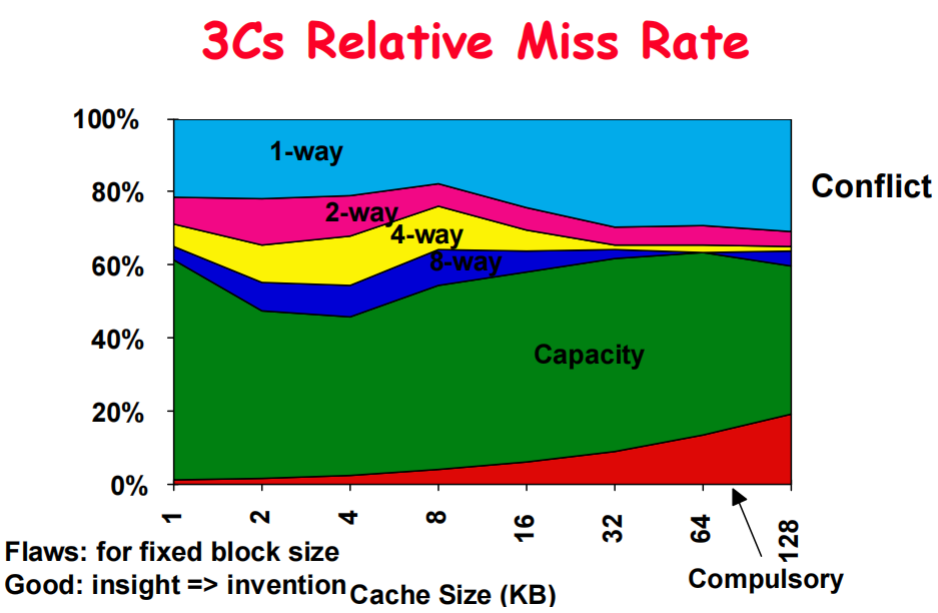

图像呈现两头小中间大

- 右侧小，中间大与上图解释相同
- 左侧小--block过少（极端情况，只有1个）时，不论Cache种类，几乎必然miss

工业上大的缓存不太关心路数，多采用2路

- Cache size 很大，2路及以上miss-rate变化不大，路数增加还会导致工艺复杂的多路比较器

具体解决方法

Change Block Size

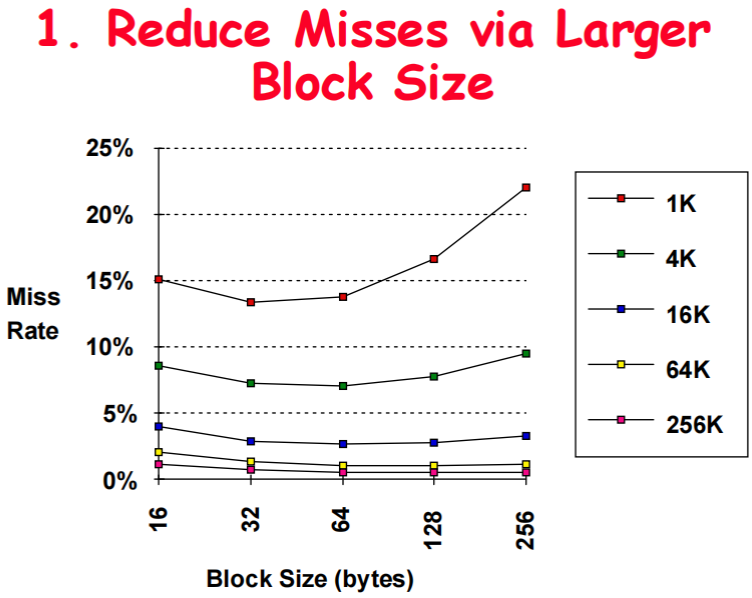

- 耦合线形状：两头低，中间高
  - 一开始下降--解决capacity问题
  - 后来上升--由于总容量固定，block size过大会导致行数过小，进而导致conflict问题
- 总容量大时，变化不明显
  - 相当于之前图线的局部放大

Example: Avg. Memory Access Time vs. Miss Rate

- Example: assume CCT = 1.10 for 2-way, 1.12 for 4-way, 1.14 for 8-way vs. CCT direct mapped

Cache Size (KB)	Associativity 1-way	2-way	4-way	8-way
1	2.33	2.15	2.07	2.01
2	1.98	1.86	1.76	1.68
4	1.72	1.67	1.61	1.53
8	1.46	1.48	1.47	1.43
16	1.29	1.32	1.32	1.32
32	1.20	1.24	1.25	1.27
64	1.14	1.20	1.21	1.23
128	1.10	1.17	1.18	1.20

(Red means A.M.A.T. not improved by more associativity)

- 实际效果不能看miss-rate, 要看AMAT
- 黑色数据--随着way的增加，miss-rate减少，AMAT进而减少
- 红色数据反常--随着way的增加，虽然miss-rate减少了，但是hit-time增加了，当hit-time影响更大时，AMAT增加

Change Associativity

Change Compiler